

智语康伴后端功能说明（客户/评审版）

更新时间：2026-04-23

1. 产品定位

智语康伴是一套面向老年陪伴与健康管理场景的智能后端系统。它不是单纯的聊天机器人，也不是单纯的健康记录本，而是把“健康档案、日常健康记录、AI 陪伴对话、医学知识库问答、长期记忆、主动关心提醒、实时消息推送”组合在一起，形成一个可持续陪伴用户的健康助理。

系统的核心目标是：

- 帮助用户记录和回顾自己的健康状态。
- 让用户可以用自然语言咨询日常健康、慢病管理、生活习惯等问题。
- 让 AI 回答尽量基于已导入的医学资料，减少凭空回答。
- 在用户长时间没有记录关键健康数据，或在聊天中表达出特定困扰时，系统可以主动提醒和关心。
- 保留必要的会话摘要和长期记忆，让陪伴更连续，但不过度打扰用户。

2. 当前后端能力总览

模块	用户能感受到的能力	当前状态
账号与登录	注册、登录、获取个人账号信息、更新基础账号信息	已完成
健康档案	维护姓名、年龄、身高、体重、慢病史、过敏史、紧急联系人等	已完成
健康记录	记录血压、血糖、睡眠、用药、情绪、健康打卡，并按时间和类型查询	已完成
AI 陪伴聊天	与健康陪伴助手对话，支持普通回复、流式回复、取消生成、重新生成	已完成
医学知识库问答	基于导入 PDF/文本资料检索后回答，并返回引用来源	已完成，依赖 embedding 服务可用
会话管理	创建会话、查看会话、修改标题、删除会话、查看消息历史	已完成
会话摘要	将一段会话压缩成摘要，用于后续连续对话	已完成，需要显式触发生成
长期记忆	保存用户偏好、健康注意事项、生活习惯等长期信息，辅助后续回答	已完成，需要显式写入
主动关心	规则先筛选可能需要关心的场景，再由 AI 结合近况判断是否提醒，最后经过后端安全、免打扰、频率和冷却审核后生成消息	已完成
主动关心窗口	用户可开启/关闭主动关心，设置免打扰时段和每日最大次数	已完成

模块	用户能感受到的能力	当前状态
触发规则	支持未记录、聊天关键词、血压阈值、血糖连续偏高、用药时间、睡眠过短、情绪连续低落等规则	已完成
主动决策记录	记录 AI 输入、AI 输出、提醒原因、严重程度、安全标签和最终拦截原因	已完成
主动行为日志	记录为什么提醒、为什么没提醒、是否被 AI、免打扰、次数限制、冷却或安全策略拦截	已完成
实时通道	WebSocket 在线推送主动关心消息， 离线后可在下次连接回放待展示消息	已完成
服务健康检查	检查后端服务是否运行、数据库是否连通	已完成

3. 用户账号与安全

用户可以注册账号，注册时需要用户名和密码，也可以绑定邮箱或手机号。系统会校验用户名、邮箱、手机号的唯一性，避免重复注册。

用户登录后获得访问凭证，后续访问个人档案、健康记录、聊天记录、主动关心消息等都需要登录身份。普通用户之间的数据是隔离的，一个用户不能查看另一个用户的健康档案、健康记录、会话、消息、长期记忆、主动关心消息和主动日志。

当前账号能力包括：

- 用户注册。
- 用户登录。
- 查看当前登录用户信息。
- 更新用户名、邮箱、手机号。
- 校验账号是否处于可用状态。

当前账号边界：

- 当前版本没有短信验证码登录。
- 当前版本没有第三方登录。
- 当前版本没有找回密码流程。
- 当前版本没有细化管理员、医生、普通用户等角色权限。

4. 健康档案

健康档案用于记录用户的基础健康背景。它相当于 AI 陪伴和健康记录系统的基础资料。

用户可维护的信息包括：

- 姓名。
- 年龄。

- 性别。
- 身高。
- 体重。
- 慢病史。
- 过敏史。
- 紧急联系人。
- 备注信息。

业务价值：

- AI 回答时可以围绕用户背景给出更贴近的日常建议。
- 后续健康记录、主动关心和风险提示可以结合用户的慢病史、过敏史等背景扩展。
- 紧急联系人字段为后续“家属协同、异常提醒、紧急联系”能力预留了用户资料基础。

当前边界：

- 当前版本只负责保存和读取档案信息。
- 当前版本不会自动根据档案生成诊断结论。
- 当前版本不会自动联系紧急联系人。

5. 健康记录

健康记录用于保存用户日常健康数据，是主动关心模块的重要输入之一。

当前支持的记录类型：

- 健康打卡： `checkin` 。
- 血压： `blood_pressure` 。
- 血糖： `blood_glucose` 。
- 睡眠： `sleep` 。
- 用药： `medication` 。
- 情绪： `mood` 。

每条记录包含：

- 记录类型。
- 记录值，例如 126/82 、 7.5 、 已服药 、 轻度焦虑 。
- 单位，例如 mmHg 、 mmol/L 、 hour 。
- 发生时间，也就是这条健康事件实际发生的时间。
- 备注，例如“早晨测量”“饭后两小时”“睡眠质量一般”。

用户能做什么：

- 新增健康记录。
- 查看自己的健康记录列表。
- 按记录类型筛选。
- 按起止时间筛选。
- 分页查看历史记录。

- 查看某条记录详情。
- 修改记录。
- 删除记录。

业务价值：

- 用户可以持续记录自己的健康状态。
- 后续 AI 对话可以结合健康记录做更自然的陪伴。
- 主动关心可以根据“多久没有记录某类数据”、血压阈值、睡眠时长、用药时间等规则触发提醒。

当前边界：

- 当前版本可在主动关心规则中做血压、血糖等阈值初筛，但不会生成医学诊断。
- 当前版本不接入穿戴设备或医疗设备自动同步。
- 当前版本不生成医学诊断报告。

6. AI 陪伴聊天

AI 聊天模块是用户与系统互动的主入口。用户可以围绕健康、生活、情绪、日常照护等内容向系统提问。

用户能做什么：

- 创建一个新会话。
- 在会话中发送文字消息。
- 获取 AI 回复。
- 使用流式回复，让回答像实时打字一样出现。
- 在流式回复过程中取消生成。
- 对某条 AI 回复重新生成。
- 查看会话消息历史。
- 修改会话标题。
- 删除会话。

AI 回复的产品定位：

- 以温和、耐心、简洁的方式陪伴用户。
- 面向老年健康陪伴场景，优先提供日常健康建议和生活方式建议。
- 涉及健康问题时，不冒充医生，不做明确诊断。
- 遇到胸痛、呼吸困难、摔倒后无法起身、意识异常、自伤倾向等高风险场景，应建议用户立即联系家属、护理人员或急救服务。

当前聊天模式：

- 默认是知识库增强模式，也就是优先尝试从医学知识库中检索资料，再生成回答。
- 也支持普通聊天模式，即不使用知识库检索，直接结合会话上下文回答。

当前边界：

- AI 回复依赖外部大模型服务可用。
- AI 回复属于健康陪伴和一般建议，不替代医生诊疗。

- 当前版本不支持图片、语音、报告单 OCR 问诊。

7. 医学知识库与 RAG 问答

医学知识库用于让 AI 回答尽量基于已导入的资料。当前系统可以导入本地文档，把文档切分成片段，生成向量，并在用户提问时检索相关片段。

支持的资料类型：

- PDF。
- TXT。
- Markdown。
- JSON。

知识库的用户可见价值：

- 用户提问时，系统可以先检索已导入的医学资料。
- AI 回答可以附带引用来源，便于查看依据来自哪份资料。
- 对医学、慢病、老年健康类问题，回答比纯聊天更有依据。
- 当知识库资料不足时，系统应说明资料不足，而不是编造结论。

知识库管理能力：

- 创建知识库。
- 查看知识库列表。
- 查看知识库详情。
- 更新知识库名称、描述和状态。
- 归档知识库。
- 导入本地文档。
- 导入默认资料目录。
- 查看文档导入状态。
- 查看文档切片。
- 按问题检索相关知识片段。

RAG 回答的表现：

- 用户提问后，系统检索最相关的知识片段。
- 检索结果会被放入 AI 回答上下文。
- 返回给前端的结果里包含引用信息，例如来源文档名、片段预览、相似度分数。
- AI 回答中尽量用 [1]、[2] 这样的编号标注依据。

当前知识库边界：

- 当前知识库是全局共享资源，不是每个用户独立一套知识库。
- 当前版本使用数据库内的向量检索，适合演示、小规模试用和早期验证。
- 如果后续文档量非常大，建议迁移到专业向量数据库。
- PDF 必须能提取出文字。纯扫描图如果没有 OCR 文本层，会被识别为无法有效导入。
- RAG 检索依赖 embedding 服务。如果 embedding 服务额度不足或不可用，知识库检索和 RAG 问答会受影响。

8. 会话摘要

会话摘要用于把一段较长的聊天压缩成简洁要点，帮助后续对话保持连续性。

用户价值：

- 用户不用每次都重复说明前面聊过什么。
- AI 可以在后续回复中参考历史摘要。
- 长会话不会无限制把所有历史消息塞进上下文，系统会用摘要提高连续性和效率。

当前能力：

- 对指定会话生成摘要。
- 可设置摘要参考的最近消息数量。
- 查看某个会话已有摘要。
- 新摘要会覆盖或更新同一会话的旧摘要。

当前边界：

- 当前版本不会自动在每次聊天后生成摘要。
- 摘要需要由前端、运营流程或后端调用显式触发。
- 摘要内容由大模型生成，依赖大模型服务可用。

9. 长期记忆

长期记忆用于保存对陪伴有长期价值的信息，例如用户偏好、健康注意事项、生活习惯等。

可记录的记忆类型：

- 用户资料类： `profile` 。
- 偏好类： `preference` 。
- 健康类： `health` 。
- 作息习惯类： `routine` 。
- 注意事项类： `caution` 。
- 自定义类： `custom` 。

每条记忆包含：

- 记忆内容。
- 记忆类型。
- 来源标记。
- 重要程度，1 到 5。
- 状态，分为 `active` 和 `archived`。

用户价值：

- AI 可以记得用户长期偏好，例如“喜欢简短回答”“不喜欢太专业术语”。
- AI 可以记得健康注意事项，例如“对某类药物过敏”“平时血压偏高”。
- AI 可以记得生活习惯，例如“晚上十点后不希望被打扰”。

当前使用方式：

- 聊天时系统会优先使用 active 状态、重要程度较高的记忆。
- 当前最多取一部分重要记忆进入聊天上下文，避免上下文过长。

当前边界：

- 当前版本的长期记忆需要显式创建、更新、归档或删除。
- 当前版本不会默认从所有聊天中自动偷偷提取长期记忆。
- 如果后续要做“自动记忆”，需要增加用户授权、记忆审核和撤回机制。

10. 主动关心模块

主动关心是当前后端最有产品特色的模块。它的目标不是让用户一直被打扰，而是在用户可能需要关心时，先用明确规则发现信号，再由 AI 结合用户近况判断是否值得提醒，最后由后端做安全和频率控制，生成一条温和的提醒。

10.1 主动关心不是固定闹钟

当前版本的主动关心不是“每天固定 8 点发一条问候”。

当前机制是“规则初筛 + AI 判断 + 后端审核”的主动关心：

- 系统会定期扫描所有活跃用户。
- 系统会按优先级检查已启用的触发规则。
- 如果规则完全不命中，系统会跳过该用户。
- 如果规则命中，系统会整理用户近况包，包括健康档案、最近健康记录、最近聊天、长期记忆和主动关心策略。
- AI 只负责判断本次是否值得提醒，并返回结构化 JSON 决策，包括是否提醒、严重程度、原因、标题、消息、冷却时间和安全标签。
- 后端会再次检查主动关心开关、免打扰时段、每日次数、同类冷却、消息长度和医疗安全边界。
- 只有 AI 判断需要提醒，并且后端审核通过，才会生成主动消息。
- 如果用户在线，系统会实时推送。
- 如果用户不在线，消息会保留为待展示状态，用户下次连接时可以收到。

默认配置下：

- 后端服务启动时会立即扫描一次。
- 之后默认每 30 分钟扫描一次。
- 扫描时间是后台周期，不是固定整点。
- 免打扰时段默认是 22:00 到次日 08:00。
- 每个用户默认每天最多生成 1 条主动关心消息。

产品表达上，可以把它描述为：

“系统不是简单定时提醒，也不是无边界地让 AI 监控用户。它先用明确规则发现可能需要关心的场景，再让 AI 结合用户档案、健康记录和近期聊天生成自然提醒，最后由后端做免打扰、频率、冷却和医疗安全控制。”

10.2 当前支持的触发规则

当前触发规则只负责判断“这个用户现在值不值得问 AI”，不直接决定最终发送。

规则类型	触发逻辑	用户感受到的效果
多天未记录健康数据	如果用户超过设定天数没有记录某类健康数据，例如血压、血糖、睡眠	系统可能提醒用户补记或测量相关健康数据
最近聊天关键词	如果用户最近若干条聊天中出现配置的关键词，例如“焦虑”“睡不着”	系统可能生成一条温和的健康关怀提示
血压超过阈值	如果最近血压记录达到配置阈值，例如收缩压不低于 140 或舒张压不低于 90	系统可能提醒用户复测、记录，并关注不适变化
血糖连续偏高	如果最近连续多次血糖记录达到配置阈值	系统可能提醒用户继续记录，并在异常明显时咨询医生
用药时间提醒	如果当前时间接近配置的用药时间窗口	系统可能提醒用户按原医嘱确认用药情况
睡眠时长过短	如果最近睡眠记录低于配置小时数，例如少于 5 小时	系统可能提醒用户关注休息和睡眠状态
情绪连续低落	如果最近多条情绪记录符合低落条件	系统可能生成温和的情绪关怀提示

这些规则的意义是“筛选信号”，不是直接给医学结论。真正是否提醒、怎么表达，还会交给 AI 决策和后端安全审核。

10.3 例子：血压超过阈值

假配置了一条规则：

- 规则名称：血压偏高提醒。
- 触发类型：血压超过阈值。
- 条件：最近 24 小时内血压达到 140/90 或以上。
- 优先级：高。

系统扫描时会检查：

- 用户最近 24 小时是否有有效血压记录。
- 血压值是否达到配置阈值。
- 用户档案中是否有慢病史等背景。
- 最近聊天中是否提到头晕、睡不好等相关线索。
- AI 是否判断这次值得提醒。
- 后端安全审核、免打扰、每日次数和同类冷却是否允许发送。

如果全部满足，用户会收到类似这样的提醒：

“我注意到你最近一次血压偏高。如果方便，建议今晚再测一次并记录；如果头晕明显加重，请及时联系家人或医生。”

这个提醒不是诊断，只是帮助用户关注记录变化和及时求助。

10.4 例子：最近聊天出现焦虑关键词

假设配置了一条规则：

- 规则名称：聊天焦虑关键词。
- 触发类型：最近聊天关键词。
- 条件：最近 10 条用户消息中出现“焦虑”。

系统扫描时会检查用户最近的聊天内容。如果用户说过“我最近有点焦虑”“晚上焦虑睡不着”，规则会命中。

如果规则命中，系统会把最近聊天、健康记录和长期记忆整理成近况包交给 AI 判断。如果 AI 认为适合提醒，且后端审核通过，用户会收到类似这样的关心：

“我注意到你最近的表达里出现了‘焦虑’相关内容。如果你愿意，可以继续说说现在最困扰你的点，我会先帮你整理成几个可执行的小建议。”

当前版本的关键词规则是关键词匹配，不是复杂情绪识别模型。它适合做明确场景的早期主动关心，例如焦虑、睡眠、用药、血压记录等。

10.5 AI 主动关心决策

规则命中后，后端会整理一个结构化“用户近况包”，交给 AI 主动关心决策器。近况包包括：

- 用户健康档案，例如年龄、性别、慢病史、过敏史。
- 本次命中的触发规则和命中原因。
- 最近健康记录。
- 最近用户聊天内容。
- 当前 active 状态的长期记忆。
- 主动关心策略，例如免打扰时段、每日最大次数、今日已提醒次数。

AI 必须返回 JSON，主要字段包括：

- `should_remind`：本次是否建议提醒。
- `severity`：严重程度，例如 low、medium、high。
- `reason`：为什么提醒或不提醒。
- `title`：提醒标题。
- `message`：最终给用户看的提醒文案。
- `cooldown_hours`：建议同类提醒冷却时间。
- `safety_label`：安全标签。

AI 不直接决定最终发送。即使 AI 返回应该提醒，后端仍会继续审核。

10.6 后端安全审核

后端会对 AI 输出做最终审核：

- 主动关心是否开启。
- 当前是否在免打扰时段。
- 今日提醒次数是否超限。

- 同类提醒是否仍在冷却期。
- AI 输出是否是合法 JSON。
- 标题和消息是否为空。
- 消息是否过长。
- 是否包含不安全医疗承诺，例如保证治愈、不用就医、建议停药等。
- 是否命中高风险场景。

高风险场景包括胸痛、呼吸困难、意识异常、严重头晕、摔倒无法起身、自伤倾向等。如果命中高风险，后端不会完全使用 AI 自由文案，而是使用固定安全模板：

“你提到的情况可能需要及时关注。建议尽快联系家人、医生或当地急救服务，避免独自等待。”

10.7 主动关心窗口

每个用户都有自己的主动关心窗口配置。

可配置项：

- 是否开启主动关心。
- 免打扰开始时间。
- 免打扰结束时间。
- 每日最大主动关心次数。

默认值：

- 开启主动关心。
- 免打扰开始：22:00。
- 免打扰结束：08:00。
- 每日最大次数：1。

如果用户关闭主动关心：

- 规则仍可被检查。
- 系统不会生成主动关心消息。
- 日志中会记录被关闭状态拦截。

如果当前处于免打扰时段：

- 系统不会在这个时间生成主动消息。
- 如果规则条件之后仍然满足，下一次非免打扰扫描时仍可能生成。

如果当天已达到次数上限：

- 系统不会继续生成新的主动关心消息。
- 日志中会记录被每日次数限制拦截。

10.8 多条规则如何避免打扰过多

系统会按规则优先级从高到低检查。优先级数字越小，越先检查。

为了避免同一次扫描连续打扰用户：

- 如果一条规则没有命中，系统会继续检查下一条规则。
- 如果一条规则命中并成功生成消息，本次扫描不会继续给同一用户生成更多消息。
- 如果一条规则命中但被 AI、免打扰、每日次数限制、安全策略或同类冷却拦截，本次扫描也会停止处理该用户，避免多条规则连续尝试。
- 同一个用户、同一个触发类型、同一条规则，在冷却时间内不会重复生成主动消息。

这个设计的产品意义是：

- 用户不会因为多个规则同时满足而短时间收到多条提醒。
- 高优先级规则会优先被处理，例如血压记录提醒可以排在普通聊天关键词关心前面。
- 系统更像“克制的陪伴”，不是“频繁轰炸”。

10.9 主动消息状态

主动关心消息有展示状态。

当前状态包括：

- `pending`：已生成但前端尚未确认展示。
- `displayed`：前端已经展示给用户，并回传确认。

用户或前端可以查看主动关心消息列表。前端展示后，可以把消息标记为已展示。

10.10 在线和离线场景

用户在线时：

- WebSocket 实时通道处于连接状态。
- 主动关心消息生成后会立即推送到用户当前连接。
- 前端可以弹出提醒、消息卡片或入口红点。

用户离线时：

- 系统仍可以生成主动关心消息。
- 消息会保留在数据库中，状态为待展示。
- 用户下次建立实时连接时，系统会回放仍处于待展示状态的主动消息。

当前边界：

- 当前实时推送依赖 WebSocket 在线连接。
- 当前版本不是手机系统级推送。
- 当前版本不发短信、电话、微信模板消息。

11. 触发规则与主动行为日志

触发规则是主动关心的配置基础。产品或运营可以用规则表达“什么时候应该关心用户”。

规则包含：

- 规则名称。
- 触发类型。
- 是否启用。
- 条件配置。
- 优先级。

当前规则能力：

- 创建规则。
- 查看规则列表。
- 查看规则详情。
- 更新规则。
- 手动检查某条规则对当前用户是否命中。
- 手动执行某条规则并尝试生成主动消息。

主动行为日志用于解释“系统为什么做了或没做某件事”。

日志会记录：

- 检查了哪条规则。
- 对哪个用户执行。
- 动作类型，例如规则检查、生成主动消息。
- 状态，例如命中、未命中、已生成、跳过、被 AI 拦截、被免打扰拦截、被每日次数限制拦截、被同类冷却拦截、被安全策略拦截、失败。
- 请求和响应摘要。
- 创建时间。

主动决策记录用于解释 AI 和后端审核链路，会保存：

- 触发规则和触发类型。
- 规则是否命中。
- AI 是否建议提醒。
- AI 给出的严重程度、原因、标题、消息、冷却时间和安全标签。
- 后端最终状态和拦截原因。
- AI 输入的用户近况包快照。
- AI 原始输出和解析后的 JSON。

产品价值：

- 方便调试主动关心是否按预期工作。
- 方便解释用户为什么收到某条提醒。
- 方便解释用户为什么没有收到提醒。
- 方便展示“AI 为什么提醒”以及“后端为什么没有直接相信 AI”。
- 后续可以作为运营分析、规则优化、用户体验评估的基础数据。

当前边界：

- 当前版本规则是全局规则，所有用户共用同一套规则。
- 当前版本没有独立的管理员权限分层，部署正式环境前建议只把规则管理入口开放给可信人员。

12. 实时消息通道

实时消息通道用于让前端与后端保持连接，从而接收主动关心消息。

当前能力：

- 用户登录后可以携带登录凭证建立 WebSocket 连接。
- 连接成功后，系统返回连接成功事件。
- 前端可以发送 ping，后端返回 pong，用于检测连接是否正常。
- 主动关心消息生成时，后端会向该用户的在线连接推送事件。
- 如果用户离线期间有待展示主动消息，用户下次连接时会收到回放。
- 支持测试推送，用于前端和部署验收。

产品价值：

- 主动关心不需要用户刷新页面才能看到。
- 前端可以做消息弹窗、通知角标、关怀卡片等体验。
- 离线消息不会因为用户当时不在线而丢失。

当前边界：

- WebSocket 只负责应用内实时推送。
- 如果用户关闭网页或 App，系统级通知需要额外接入移动推送、短信或小程序订阅消息。

13. 服务健康检查

后端提供基础健康检查能力，用于部署和运维。

当前能力：

- 检查服务是否运行。
- 检查数据库是否可以连接。

产品价值：

- 部署后可以快速确认后端服务是否正常。
- 云服务器、Nginx、前端联调时可以先用健康检查定位问题。
- 后续可以接入监控平台，用于告警和可用性监测。

14. 时间和时区

当前系统统一按北京时间处理核心业务时间。

涉及的时间包括：

- 用户注册时间。
- 档案创建和更新时间。
- 健康记录发生时间。
- 聊天消息创建和更新时间。
- 主动关心消息创建和展示时间。
- 主动行为日志时间。
- 后台主动扫描时间。

产品意义：

- 国内用户看到的时间更符合直觉。
- 主动关心的免打扰时段按北京时间判断。
- 日志排查时不容易出现 UTC 和本地时间混淆。

15. 医疗安全边界

当前系统定位是健康陪伴和健康管理辅助，不是医疗诊断系统。

应对外明确：

- 系统可以提供日常健康建议。
- 系统可以提醒用户记录数据或关注身体状态。
- 系统可以基于知识库资料辅助解释健康问题。
- 系统不能替代医生诊断。
- 系统不能直接给出处方或调整药物剂量。
- 遇到急症或高风险情况，应建议用户尽快联系医生、家属或急救服务。

建议产品话术：

“智语康伴提供健康陪伴、健康记录和一般性健康建议，不替代专业医疗诊断和治疗。如出现胸痛、呼吸困难、意识异常、严重不适等情况，请及时就医或联系急救服务。”

16. 当前版本不包含的能力

为避免评审或客户误解，以下能力当前不应承诺为已完成：

- 不支持固定某个精确时间点给每个用户发送每日问候。
- 不支持短信、电话、微信、小程序订阅消息等外部推送。
- 不支持医生端、家属端、管理员端的完整角色体系。
- 不支持穿戴设备和医疗设备自动同步。
- 不支持自动识别体检报告图片。
- 不支持药品相互作用专业审方。
- 不支持自动生成医学诊断。
- 不支持自动拨打紧急联系人电话。
- 不支持大规模生产级向量数据库集群。
- 不支持后台任务队列和分布式异步任务。

这些能力可以作为后续路线图，但不应作为当前已交付能力对外介绍。

17. 推荐演示流程

如果给评委或产品经理演示，建议按下面顺序讲。

1. 用户注册并登录。
2. 用户填写健康档案，例如年龄、慢病史、过敏史、紧急联系人。
3. 用户录入几条健康记录，例如血压、睡眠、情绪。
4. 用户进入 AI 聊天，询问一个健康问题。
5. 系统使用知识库检索资料，并给出带引用的回答。
6. 用户继续聊天，系统保留会话历史。
7. 生成会话摘要，说明系统可以延续长期陪伴上下文。
8. 写入一条长期记忆，例如“用户有高血压史，回答尽量简短”。
9. 配置主动关心规则，例如“血压超过 140/90”或“睡眠少于 5 小时”。
10. 手动执行主动关心规则，展示规则如何先筛选信号。
11. 展示 AI 主动关心决策记录，说明 AI 为什么建议提醒或不提醒。
12. 展示主动关心窗口、每日次数限制和同类冷却，说明系统如何避免过度打扰。
13. 打开实时通道，展示主动关心消息可以实时推送。
14. 查看主动行为日志，解释为什么触发、为什么拦截、为什么生成消息。

18. 主动关心模块推荐介绍词

可以这样对评委或客户介绍：

“我们的主动关心不是简单的定时问候，也不是让 AI 无边界地监控用户。系统会先用明确规则发现可能需要关心的场景，例如血压超过 140/90、睡眠少于 5 小时、接近用药时间等；规则命中后，再把用户档案、最近健康记录、近期聊天和长期记忆整理成近况包，由 AI 判断是否值得提醒并生成自然文案；最后后端还会做免打扰、每日次数、同类冷却和医疗安全审核。只有全部通过后，才会生成主动消息并通过 WebSocket 推送或保留待展示。”

也可以这样解释聊天关键词关心：

“如果用户最近聊天中提到焦虑、睡不着、头晕等关键词，系统不会立刻机械发送固定话术，而是先让规则命中，再交给 AI 结合近况判断是否提醒。即使 AI 建议提醒，后端也会继续做安全审核。遇到胸痛、呼吸困难、意识异常、自伤倾向等高风险线索时，系统会使用固定安全模板，建议用户及时联系家人、医生或急救服务。”

19. 部署前内部确认项

以下内容不一定对客户展示，但建议团队部署前确认。

19.1 数据库和知识库文件

当前数据库已经包含知识库切片和向量，体积会越来越大，不建议上传 GitHub。

建议：

- GitHub 只放代码、迁移脚本、依赖说明和部署配置。
- 数据库文件放在云服务器磁盘。
- PDF 和知识库源文件放在云服务器存储目录。
- 定期备份数据库和知识库源文件。

19.2 当前本地知识库导入状态

截至 2026-04-23 当前本地数据库状态：

- 知识库：1 个，名称为“公共医学知识库”。
- 文档记录：18 个。
- 已完成文档：11 个。
- 向量切片：6543 条。
- 失败文档：7 个。
- 另有 4 个新增 PDF 还未继续尝试导入。

失败原因是 embedding 服务返回“余额不足或无可资源包”。如果部署时希望完整使用新增 PDF，需要先补充 embedding 服务额度，然后重新执行导入流程。

19.3 当前本地触发规则状态

当前本地数据库可能存在演示和验收用触发规则，例如血压阈值提醒、睡眠过短提醒、用药时间提醒和聊天关键词提醒。

部署前建议：

- 清理重复的验收规则。
- 明确哪些规则作为正式默认规则保留。
- 确认规则优先级。
- 确认默认免打扰时段和每日提醒次数。
- 确认同类提醒冷却策略。
- 确认主动关心所需的大模型配置可用，否则规则命中后无法完成 AI 决策。

19.4 正式环境配置

部署前需要确认：

- 数据库地址。
- JWT 密钥。
- 大模型 API Key、Base URL 和模型名称。
- Embedding API Key、Base URL 和模型名称。
- CORS 允许的前端域名。
- WebSocket 是否开启。
- 主动扫描是否开启。
- 主动扫描间隔。
- 服务器时区和系统时间。
- 数据库备份策略。

19.5 权限策略

当前普通登录用户即可访问知识库管理和触发规则管理相关接口。因为知识库和触发规则是全局资源，正式部署前建议：

- 如果只是内部演示，可以保持现状。
- 如果面向真实用户开放，需要增加管理员权限控制。
- 普通用户端不应暴露知识库导入、规则创建、全局规则修改等入口。

20. 最小验收清单

部署前建议至少完成以下验收。

1. 注册和登录成功。
2. 登录后能获取当前用户信息。
3. 能创建和更新健康档案。
4. 能新增、筛选、修改、删除健康记录。
5. 能创建会话并发送普通聊天消息。
6. 能发送流式聊天消息。
7. 能取消流式生成。
8. 能重新生成 AI 回复。
9. 能导入至少一个知识库文档并完成切片。
10. 能进行知识库检索并返回引用。
11. RAG 聊天能返回带引用的回答。
12. 能生成会话摘要。
13. 能创建长期记忆，并在后续聊天中体现。
14. 能创建或保留一条主动关心规则，例如血压阈值、睡眠过短、用药时间或聊天关键词。
15. 能设置主动关心窗口。
16. 能手动检查规则是否命中。
17. 能手动执行规则，并触发 AI 主动关心决策。
18. 能查看主动决策记录，包括 AI 是否建议提醒、提醒原因、严重程度、安全标签和后端最终状态。
19. AI 判断不提醒时，不会生成主动消息。
20. 免打扰时段内不会生成主动消息。
21. 每日次数达到上限后不会继续生成主动消息。
22. 同类提醒在冷却期内不会重复生成。
23. 高风险关键词命中时会使用后端固定安全模板。
24. WebSocket 连接后能收到实时测试推送。
25. 主动消息生成后，在线用户能收到实时事件。
26. 离线期间生成的待展示主动消息，用户下次连接时能回放。
27. 主动行为日志能解释触发、跳过、拦截和失败原因。
28. 服务健康检查通过。
29. 数据库健康检查通过。

21. 一句话总结

当前后端已经具备健康陪伴产品的核心闭环：用户建档和记录健康数据，AI 基于医学知识库进行对话，系统通过摘要和长期记忆维持连续陪伴，并能通过“规则初筛、AI 判断、后端安全限流”的方式进行克制的主动关心。部署前需要重点确知识库向量导入、大模型与 embedding 服务额度、全局管理权限和生产环境配置。